

Este notebook realiza uma **Análise Exploratória de Dados (EDA)** na base cinematográfica entregue em CSV. O objetivo é entender as principais características dos filmes, levantar hipóteses e orientar a **PProductions** sobre quais tipos de filmes tendem a performar melhor.

Entrada esperada: data/movies.csv contendo as colunas: Series_Title, Released_Year, Certificate, Runtime, Genre, IMDB_Rating, Overview, Meta_score, Director, Star1, Star2, Star3, Star4, No_of_Votes, Gross.

1. Carregamento dos dados

Shape: (999, 16)

ι	Jnnamed: 0	Series_Title	Released_Year	Certificate	Runtime	Genre	IMDB_Rating	Overview	Meta_score	Director	Star1	Star2	Star3	Star4	No_of_Vot
0	1	The Godfather	1972	А	175 min	Crime, Drama	9.2	An organized crime dynasty's aging patriarch t	100.0	Francis Ford Coppola	Marlon Brando	Al Pacino	James Caan	Diane Keaton	16203
1	2	The Dark Knight	2008	UA	152 min	Action, Crime, Drama	9.0	When the menace known as the Joker wreaks havo	84.0	Christopher Nolan	Christian Bale	Heath Ledger	Aaron Eckhart	Michael Caine	23032:
2	3	The Godfather: Part II	1974	А	202 min	Crime, Drama	9.0	The early life and career of Vito Corleone in	90.0	Francis Ford Coppola	Al Pacino	Robert De Niro	Robert Duvall	Diane Keaton	11299!

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 999 entries, 0 to 998
Data columns (total 16 columns):

#	Column	Non-Null Count	Dtype
0	Unnamed: 0	999 non-null	int64
1	Series_Title	999 non-null	object
2	Released_Year	999 non-null	object
3	Certificate	898 non-null	object
4	Runtime	999 non-null	object
5	Genre	999 non-null	object
6	<pre>IMDB_Rating</pre>	999 non-null	float64
7	Overview	999 non-null	object
8	Meta_score	842 non-null	float64
9	Director	999 non-null	object
10	Star1	999 non-null	object
11	Star2	999 non-null	object
12	Star3	999 non-null	object
13	Star4	999 non-null	object
14	No_of_Votes	999 non-null	int64
15	Gross	830 non-null	object
dtyp	es: float64(2),	int64(2), objec	t(12)

memory usage: 125.0+ KB

	count	mean	std	min	25%	50%	75%	max
Unnamed: 0	999.0	500.000000	288.530761	1.0	250.5	500.0	749.5	999.0
IMDB_Rating	999.0	7.947948	0.272290	7.6	7.7	7.9	8.1	9.2
Meta_score	842.0	77.969121	12.383257	28.0	70.0	79.0	87.0	100.0
No_of_Votes	999.0	271621.422422	320912.621055	25088.0	55471.5	138356.0	373167.5	2303232.0

2. Limpeza & Parsing de colunas


Transformações principais:


- **Runtime** → minutos (inteiro)
- **Gross** → número (float), removendo separadores
- Released_Year → inteiro
- **Genre** → lista de gêneros + gênero principal (Genre_Primary)


	Unnamed: 0	Series_Title	Released_Year	Certificate	Runtime	Genre	IMDB_Rating	Overview	Meta_score	Director	Star1	Star2	Star3	Star4	No_of_Vot
0	1	The Godfather	1972	А	175 min	Crime, Drama	9.2	An organized crime dynasty's aging patriarch t	100.0	Francis Ford Coppola	Marlon Brando	Al Pacino	James Caan	Diane Keaton	16203
1	2	The Dark Knight	2008	UA	152 min	Action, Crime, Drama	9.0	When the menace known as the Joker wreaks havo	84.0	Christopher Nolan	Christian Bale	Heath Ledger	Aaron Eckhart	Michael Caine	23032:
2	3	The Godfather: Part II	1974	А	202 min	Crime, Drama	9.0	The early life and career of Vito Corleone in	90.0	Francis Ford Coppola	Al Pacino	Robert De Niro	Robert Duvall	Diane Keaton	11299!

	missing_ratio
Gross_num	0.169169
Gross	0.169169
Meta_score	0.157157
Certificate	0.101101
Released_Year_int	0.001001
Unnamed: 0	0.000000
Star3	0.000000
Genre_List	0.000000
Runtime_min	0.000000
No_of_Votes	0.000000
Star4	0.000000
Star1	0.000000
Star2	0.000000
Series_Title	0.000000
Director	0.000000


3. Distribuições básicas









4. Relações entre variáveis








	IMDB_Rating	Meta_score	No_of_Votes	Gross_num	Runtime_min	Released_Year_int
IMDB_Rating	1.000000	0.271374	0.479308	0.099393	0.242751	-0.133257
Meta_score	0.271374	1.000000	-0.020091	-0.030480	-0.031604	-0.339291
No_of_Votes	0.479308	-0.020091	1.000000	0.589527	0.172483	0.246005
Gross_num	0.099393	-0.030480	0.589527	1.000000	0.140002	0.233270
Runtime_min	0.242751	-0.031604	0.172483	0.140002	1.000000	0.165765
Released_Year_int	-0.133257	-0.339291	0.246005	0.233270	0.165765	1.000000


5. Cortes por Gênero e Certificado



Genre_Primary

8.350000 Western Crime 8.016822 8.000000 Fantasy 7.975000 Mystery Film-Noir 7.966667 Drama 7.952778 Action 7.949419 Biography 7.938636 Adventure 7.937500 7.930488 Animation 7.909091 Horror 7.901290 Comedy


Name: IMDB_Rating, dtype: float64



Genre_Primary

Animation 75082668.0 Action 66208183.0 Horror 51500184.5 Biography 46836394.0 Adventure 44824144.0 14378331.0 Mystery Comedy 10728127.0 Western 10550000.0 Crime 10095170.0 Drama 8264530.0 Film-Noir 1278625.5 Fantasy NaN

Name: Gross_num, dtype: float64



```
Certificate
TV-14
            8.300000
16
            8.100000
TV-MA
            8.100000
            8.100000
Unrated
Passed
            8.020588
G
            8.000000
Α
            7.992347
U
            7.976923
UA
            7.957143
Approved
            7.945455
PG
            7.927027
TV-PG
            7.900000
R
            7.869863
GP
            7.850000
PG-13
            7.797674
            7.600000
```

Name: IMDB_Rating, dtype: float64

6. Diretores e Elenco


	n_filmes	imdb_mean
Director		
Milos Forman	2	8.500000
Christopher Nolan	8	8.462500
Francis Ford Coppola	5	8.400000
Peter Jackson	5	8.400000
Charles Chaplin	6	8.333333
Fritz Lang	2	8.300000
Lee Unkrich	2	8.300000
Nitesh Tiwari	2	8.300000
Sergio Leone	6	8.266667
Andrew Stanton	2	8.250000
Damien Chazelle	2	8.250000
Stanley Kubrick	9	8.233333
Akira Kurosawa	10	8.220000
Frank Capra	4	8.200000
Michael Curtiz	2	8.200000

n imdb	_mear
--------	-------

Star		
Elijah Wood	3	8.800000
Orlando Bloom	4	8.600000
Mark Hamill	3	8.533333
Madhavan	3	8.466667
Marlon Brando	4	8.425000
Lee J. Cobb	3	8.366667
Charles Chaplin	6	8.333333
James Caan	3	8.333333
Kevin Spacey	5	8.300000
Carrie Fisher	4	8.300000
Takashi Shimura	4	8.300000
Henry Fonda	4	8.275000
Robert Duvall	4	8.275000
Paresh Rawal	4	8.275000
Ralph Fiennes	3	8.266667

7. Overview: nuvem de palavras

A ideia é inspecionar termos mais frequentes em filmes com notas altas vs notas baixas.



Overview — Notas Baixas (< mediana 7.90)



8. NLP rápido: é possível inferir o gênero a partir da Overview?

Sim. Abaixo, um baseline com TF-IDF + Regressão Logística prevendo o gênero principal a partir da sinopse.

Acurácias (cv=5): [0.345 0.34 0.335 0.34 0.337]

Acurácia média: 0.339

9. Hipóteses iniciais

• H1: Filmes do gênero Drama tendem a ter notas IMDb mais altas, mas bilheteria mediana menor do que gêneros de ação/aventura.

- H2: No_of_Votes (popularidade) está positivamente relacionado com Gross e com a nota IMDb (efeito de sobrevivência e boca a boca).
- H3: Meta_score tem correlação positiva com IMDB_Rating (crítica especializada influencia percepção do público).
- H4: Certificate do tipo PG-13 tende a maximizar bilheteria por atingir um público mais amplo.
- H5: É possível inferir o gênero do filme a partir da Overview com acurácia superior ao acaso usando TF-IDF (e potencialmente melhor com embeddings).

10. Próximos passos

- 1. Refinar limpeza de dados (tratamento robusto de Gross, Runtime, outliers).
- 2. Enriquecer com dados externos (orçamento, prêmios, janela de lançamento / sazonalidade).
- 3. Testar diferentes modelos para prever IMDB_Rating (regressão): Regressão Linear, Random Forest, Gradient Boosting.
- 4. Medir performance com RMSE/MAE e validação cruzada.
- 5. Gerar relatório consolidado (exportar HTML/PDF) para stakeholders da PProductions.